Tarea 1. Fundamentos Matemáticos.

Tarea 1

Mónica de Santos

Curso 2021-22. Última actualización: 2021-09-20

Instrucciones preliminares

- Empieza abriendo el proyecto de RStudio correspondiente a tu repositorio personal de la asignatura.
- En todas las tareas tendrás que repetir un proceso como el descrito en la sección *Repite los pasos Creando un fichero Rmarkdown para esta práctica* de la *Práctica00*. Puedes releer la sección *Practicando la entrega de las Tareas* de esa misma práctica para recordar el procedimiento de entrega.

Ejercicio 0

- Si no has hecho los *Ejercicios* de la *Práctica00* (págs. 12 y 13) hazlos ahora y añádelos a esta tarea. Si ya los has hecho y entregado a través de GitHub no hace falta que hagas nada.

```
library(tidyverse)
```

```
## -- Attaching packages --------------------------------------- tidyverse 1.3.1 --

## v ggplot2 3.3.3     v purrr   0.3.4
## v tibble  3.1.2     v dplyr   1.0.6
## v tidyr   1.1.3     v stringr 1.4.0
## v readr   1.4.0     v forcats 0.5.1

## -- Conflicts ------------------------------------------ tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()    masks stats::lag()
```

```
library(dplyr)
```

PRÁCTICA 0

Ejercicio 1:

```
dado_honesto = sample(1:6,100, replace = TRUE)
dado_honesto
```

```
##   [1] 1 2 6 6 6 4 6 5 2 5 3 6 4 1 2 4 4 4 1 4 5 6 4 4 3 4 4 5 1 1 4 3 6 1 4 6 2
##  [38] 6 1 1 1 4 4 1 1 3 2 5 6 5 2 3 2 3 2 2 6 1 2 3 1 4 5 4 3 6 5 3 3 3 2 2 2 3
##  [75] 4 3 3 4 5 5 2 3 3 2 3 1 4 4 5 2 1 3 2 5 2 6 3 3 1 2
```

```
#Tabla de frecuencias absolutas:

table(dado_honesto)
```

```
## dado_honesto
##  1  2  3  4  5  6
## 16 19 20 20 12 13
```

```
#Tabla de frecuencias relativas

prop.table(table(dado_honesto))
```

```
## dado_honesto
##    1    2    3    4    5    6
## 0.16 0.19 0.20 0.20 0.12 0.13
```

Ejercicio 2:

```
dado_cargado = sample(1:6, 100, prob = c(1,1,1,1,1,2),replace = TRUE)

#Tabla de frecuencias absolutas:

table(dado_cargado)
```

```
## dado_cargado
##  1  2  3  4  5  6
##  7 15 15 15 18 30
```

```
#Tabla de frecuencias relativas

prop.table(table(dado_cargado))
```

```
## dado_cargado
##    1    2    3    4    5    6
## 0.07 0.15 0.15 0.15 0.18 0.30
```

Ejercicio 3:

```
#vectores con rep y seq

v1 = rep(c(4,3,2,1),c(4,4,4,4))
v2 = rep(seq(1:5),(c(1,2,3,4,5)))
v3 = rep(1:4,c(4))
```

Ejercicio 4:

```
mpg2 = mpg %>%
  filter(class == "pickup") %>%
  select(starts_with("c"))
mpg2
```

```
## # A tibble: 33 x 3
##      cyl   cty class
##    <int> <int> <chr>
##  1     6    15 pickup
##  2     6    14 pickup
##  3     6    13 pickup
##  4     6    14 pickup
##  5     8    14 pickup
##  6     8    14 pickup
##  7     8     9 pickup
##  8     8    11 pickup
##  9     8    11 pickup
## 10     8    12 pickup
## # ... with 23 more rows
```

Ejercicio 5:

```
library(haven)
census <- read_dta("C:/Users/HP Omen/Downloads/census.dta")
```

```
library(ggplot2)

# 5.1 Poblaciones totales de las regiones censales
census %>%
  group_by(region) %>%
  summarise(poblacion = sum(pop))
```

```
## # A tibble: 4 x 2
##        region poblacion
##     <dbl+lbl>     <dbl>
## 1 1 [NE]       49135283
## 2 2 [N Cntrl]  58865670
## 3 3 [South]    74734029
## 4 4 [West]     43172490
```

```
# 5.2 Poblaciones totales en diagrama de barras



#5.3 Ordenar estados por población de mayor a menor
census %>%
arrange(desc(pop))
```

```
## # A tibble: 50 x 12
##    state       region    pop poplt5 pop5_17 pop18p pop65p popurban medage  death
##    <chr>    <dbl+lbl>  <dbl>  <dbl>   <dbl>  <dbl>  <dbl>    <dbl>  <dbl>  <dbl>
```

```
##  1 Califor~ 4 [West]  2.37e7 1.71e6 4680558 1.73e7 2.41e6 21607606   29.9 186428
##  2 New York 1 [NE]    1.76e7 1.14e6 3551938 1.29e7 2.16e6 14858068   31.9 171769
##  3 Texas    3 [South] 1.42e7 1.17e6 3137045 9.92e6 1.37e6 11333017   28.2 108019
##  4 Pennsyl~ 1 [NE]    1.19e7 7.47e5 2375838 8.74e6 1.53e6  8220851   32.1 123261
##  5 Illinois 2 [N Cnt~ 1.14e7 8.42e5 2400796 8.18e6 1.26e6  9518039   29.9 102230
##  6 Ohio     2 [N Cnt~ 1.08e7 7.87e5 2307170 7.70e6 1.17e6  7918259   29.9  98268
##  7 Florida  3 [South] 9.75e6 5.70e5 1789412 7.39e6 1.69e6  8212385   34.7 104190
##  8 Michigan 2 [N Cnt~ 9.26e6 6.85e5 2066873 6.51e6 9.12e5  6551551   28.8  75102
##  9 New Jer~ 1 [NE]    7.36e6 4.63e5 1527572 5.37e6 8.60e5  6557377   32.2  68762
## 10 N. Caro~ 3 [South] 5.88e6 4.04e5 1253659 4.22e6 6.03e5  2822852   29.6  48426
## # ... with 40 more rows, and 2 more variables: marriage <dbl>, divorce <dbl>
```

```
# 5.4 Nueva variable tasa de divorcios/matrimonios
census %>%
  mutate(tasa = divorce/marriage)
```

```
## # A tibble: 50 x 13
##    state      region     pop poplt5 pop5_17 pop18p pop65p popurban medage  death
##    <chr>    <dbl+lb>   <dbl>  <dbl>   <dbl>  <dbl>  <dbl>    <dbl>  <dbl>  <dbl>
##  1 Alabama  3 [Sout~  3.89e6 2.96e5  865836 2.73e6 4.40e5  2337713   29.3  35305
##  2 Alaska   4 [West]  4.02e5 3.89e4   91796 2.71e5 1.15e4   258567   26.1   1604
##  3 Arizona  4 [West]  2.72e6 2.14e5  577604 1.93e6 3.07e5  2278728   29.2  21226
##  4 Arkansas 3 [Sout~  2.29e6 1.76e5  495782 1.62e6 3.12e5  1179556   30.6  22676
##  5 Califor~ 4 [West]  2.37e7 1.71e6 4680558 1.73e7 2.41e6 21607606   29.9 186428
##  6 Colorado 4 [West]  2.89e6 2.16e5  592318 2.08e6 2.47e5  2329869   28.6  18925
##  7 Connect~ 1 [NE]    3.11e6 1.85e5  637731 2.28e6 3.65e5  2449774   32    26005
##  8 Delaware 3 [Sout~  5.94e5 4.12e4  125444 4.28e5 5.92e4   419819   29.8   5123
##  9 Florida  3 [Sout~  9.75e6 5.70e5 1789412 7.39e6 1.69e6  8212385   34.7 104190
## 10 Georgia  3 [Sout~  5.46e6 4.15e5 1231195 3.82e6 5.17e5  3409081   28.7  44230
## # ... with 40 more rows, and 3 more variables: marriage <dbl>, divorce <dbl>,
## #   tasa <dbl>
```

```
# 5.5 Estados más envejecidos
census_mayores = census %>%
select(state,pop,pop65p,medage) %>%
mutate(tasa_mayores = pop65p/pop) %>%
arrange(desc(medage)) %>%
head(10)

census_mayores
```

```
## # A tibble: 10 x 5
##    state              pop  pop65p medage tasa_mayores
##    <chr>            <dbl>   <dbl>  <dbl>        <dbl>
##  1 Florida        9746324 1687573   34.7        0.173
##  2 New Jersey     7364823  859771   32.2        0.117
##  3 Pennsylvania  11863895 1530933   32.1        0.129
##  4 Connecticut    3107576  364864   32          0.117
##  5 New York      17558072 2160767   31.9        0.123
##  6 Rhode Island    947154  126922   31.8        0.134
##  7 Massachusetts  5737037  726531   31.2        0.127
##  8 Missouri       4916686  648126   30.9        0.132
##  9 Arkansas       2286435  312477   30.6        0.137
## 10 Maine          1124660  140918   30.4        0.125
```

```r
# 5.6 Histograma "medage" y curva de densidad
vec = seq(min(census$medage), max(census$medage), length.out=11)
ggplot(data=census, aes(x=medage))+ geom_histogram(aes(y=stat(density)), breaks=vec, fill="blue", color=
```

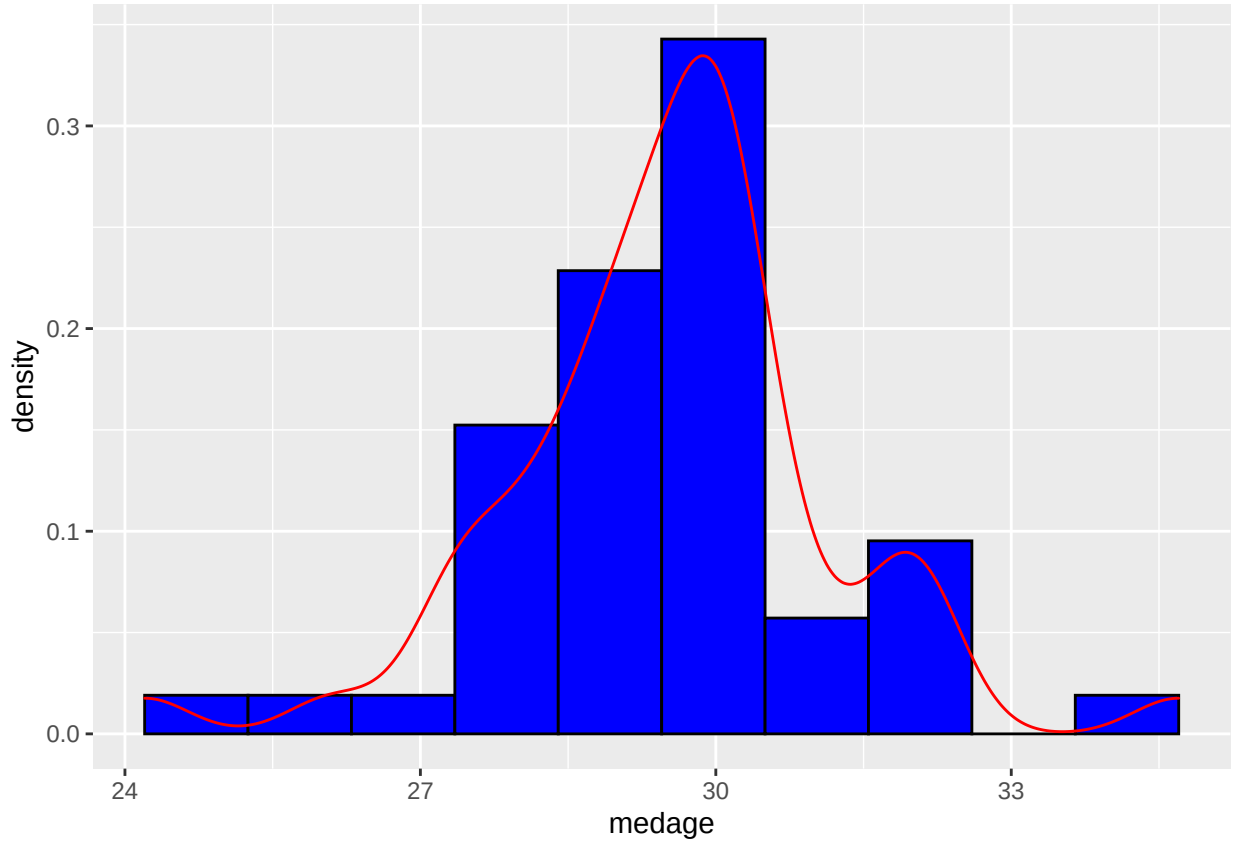

Ejercicio 1. Análisis exploratorio de un conjunto de datos y operaciones con dplyr.

- Vamos a utilizar el conjunto de datos contenido en el fichero (es un enlace):
  cholesterol.csv
  Los datos proceden de un estudio realizado en la *University of Virginia School of Medicine* que investiga la prevalencia de la obesidad, la diabetes y otros factores de riesgo cardiovascular. Se puede encontrar más información sobre el fichero en este enlace:
  https://biostat.app.vumc.org/wiki/pub/Main/DataSets/diabetes.html
- Carga el conjunto de datos en un data.frame de R llamado `chlstrl`.

```r
library(tidyverse)
library(dplyr)

chlstrl = read_csv("C:/Users/HP Omen/Documents/MASTER/Fundamentos Matemáticos/datos/cholesterol.csv")
```

```
##
## -- Column specification --------------------------------------------------------
```

```
## cols(
##   chol = col_double(),
##   age = col_double(),
##   gender = col_character(),
##   height = col_double(),
##   weight = col_double(),
##   waist = col_double(),
##   hip = col_double()
## )
```

- Empezaremos por información básica sobre el conjunto de datos. Cuántas observaciones contiene, cuáles son las variables y de qué tipos,... Información sobre los datos

```
head(chlstrl)
```

```
## # A tibble: 6 x 7
##    chol   age gender height weight waist   hip
##   <dbl> <dbl> <chr>   <dbl>  <dbl> <dbl> <dbl>
## 1   203    46 female     62    121    29    38
## 2   165    29 female     64    218    46    48
## 3   228    58 female     61    256    49    57
## 4    78    67 male       67    119    33    38
## 5   249    64 male       68    183    44    41
## 6   248    34 male       71    190    36    42
```

```
#número de filas
nrow(chlstrl)
```

```
## [1] 403
```

```
#número de columnas
ncol(chlstrl)
```

```
## [1] 7
```

```
#nombres de las variables
names(chlstrl)
```

```
## [1] "chol"   "age"    "gender" "height" "weight" "waist"  "hip"
```

```
#clase de las variables
chlstrl %>%
  sapply(class)
```

```
##        chol         age      gender      height      weight       waist
##   "numeric"   "numeric" "character"   "numeric"   "numeric"   "numeric"
##         hip
##   "numeric"
```

- Asegúrate de comprobar si hay datos ausentes y localízalos en la tabla. NA's

```
colSums(is.na(chlstrl))
```

```
##   chol    age gender height weight  waist    hip
##      1      0      0      5      1      2      2
```

- El análisis exploratorio (numérico y gráfico) debe cubrir todos los tipos de variable de la tabla. Es decir, que al menos debes estudiar una variable por cada tipo de variable presente en la tabla. El análisis debe contener, al menos:
  - Para las variables cuantittativas (continuas o discretas).
    Resumen numérico básico.
    Gráficas (las adecuadas, a ser posible más de un tipo de gráfico).
  - Variables categóricas (factores).
    Tablas de frecuencia (absolutas y relativas).
    Gráficas (diagrama de barras).

Análisis Exploratorio de los datos

```
summary(chlstrl)
```

```
##       chol            age           gender              height
##  Min.   : 78.0   Min.   :19.00   Length:403         Min.   :52.00
##  1st Qu.:179.0   1st Qu.:34.00   Class :character   1st Qu.:63.00
##  Median :204.0   Median :45.00   Mode  :character   Median :66.00
##  Mean   :207.8   Mean   :46.85                      Mean   :66.02
##  3rd Qu.:230.0   3rd Qu.:60.00                      3rd Qu.:69.00
##  Max.   :443.0   Max.   :92.00                      Max.   :76.00
##  NA's   :1                                          NA's   :5
##      weight          waist           hip
##  Min.   : 99.0   Min.   :26.0   Min.   :30.00
##  1st Qu.:151.0   1st Qu.:33.0   1st Qu.:39.00
##  Median :172.5   Median :37.0   Median :42.00
##  Mean   :177.6   Mean   :37.9   Mean   :43.04
##  3rd Qu.:200.0   3rd Qu.:41.0   3rd Qu.:46.00
##  Max.   :325.0   Max.   :56.0   Max.   :64.00
##  NA's   :1       NA's   :2      NA's   :2
```

```
#Variables Numéricas

hist(chlstrl$chol,freq = FALSE, main = "Histograma y densidad",
     ylab = "Densidad")
dx <- density(chlstrl$chol,na.rm = TRUE)
lines(dx, lwd = 2, col = "red")
```

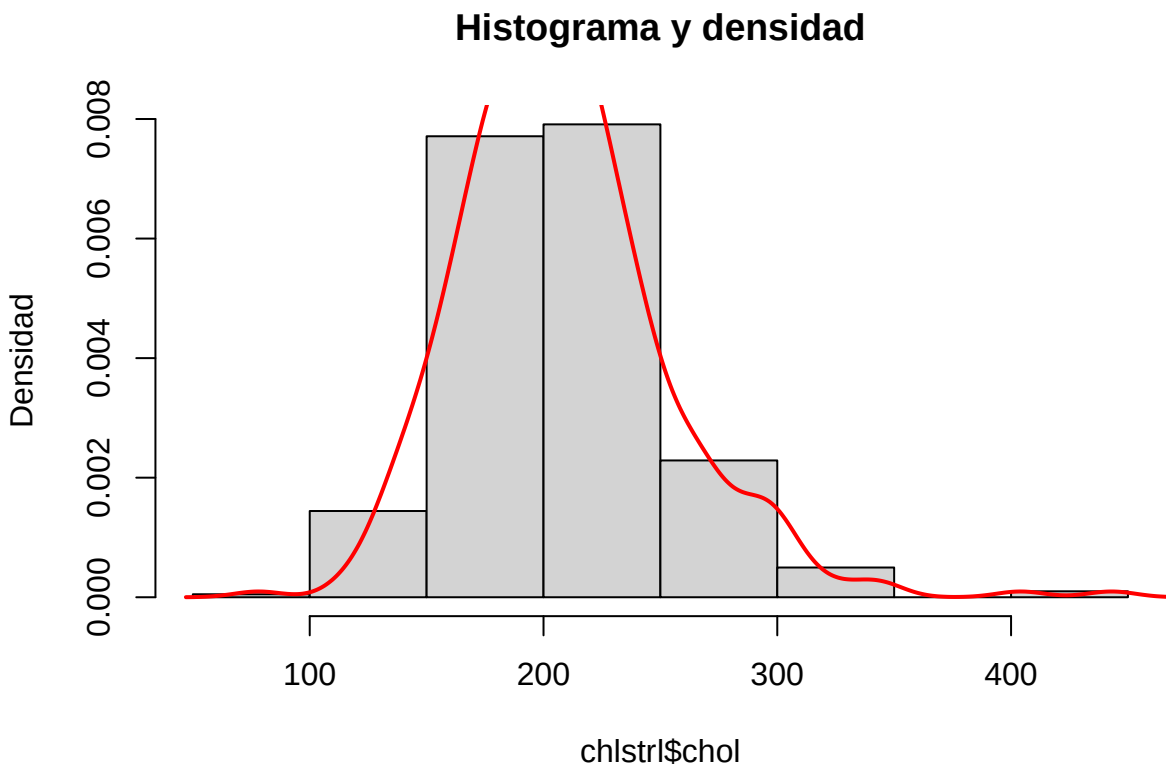


```
hist(chlstrl$age,freq = FALSE, main = "Histograma y densidad",
     ylab = "Densidad")
dx <- density(chlstrl$age,na.rm = TRUE)
lines(dx, lwd = 2, col = "red")
```

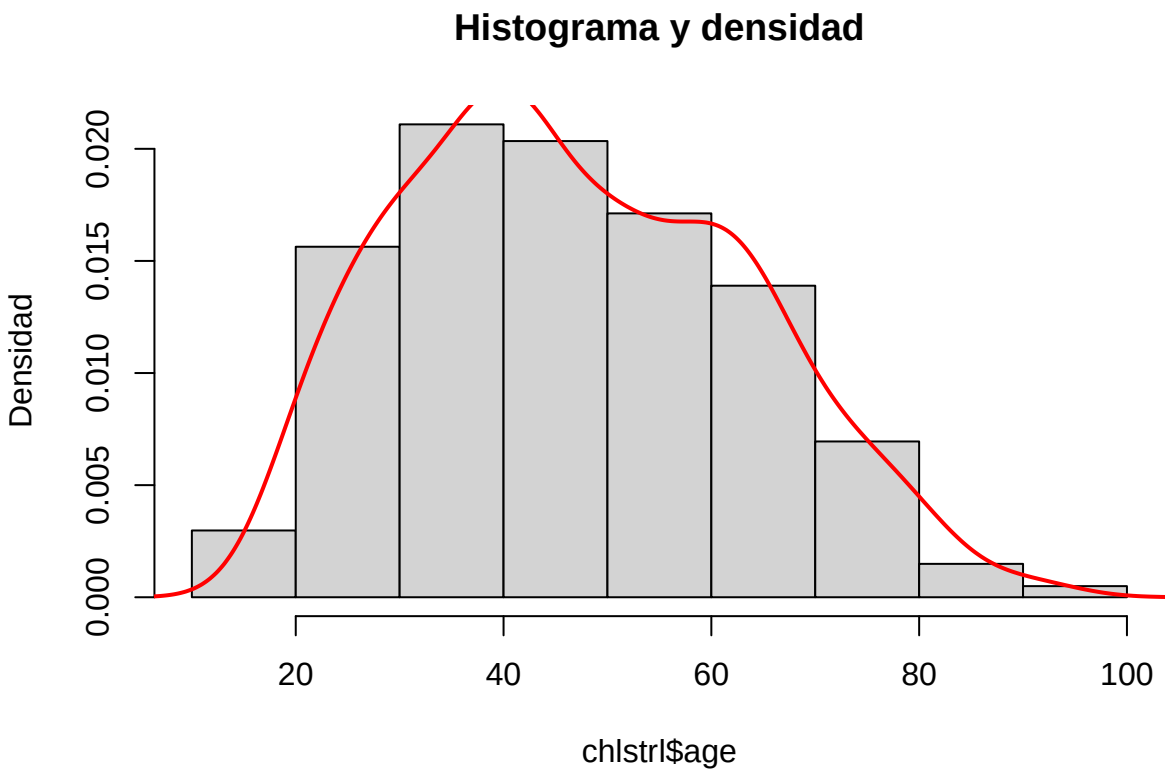


```
hist(chlstrl$height,freq = FALSE, main = "Histograma y densidad",
     ylab = "Densidad")
dx <- density(chlstrl$height,na.rm = TRUE)
lines(dx, lwd = 2, col = "red")
```

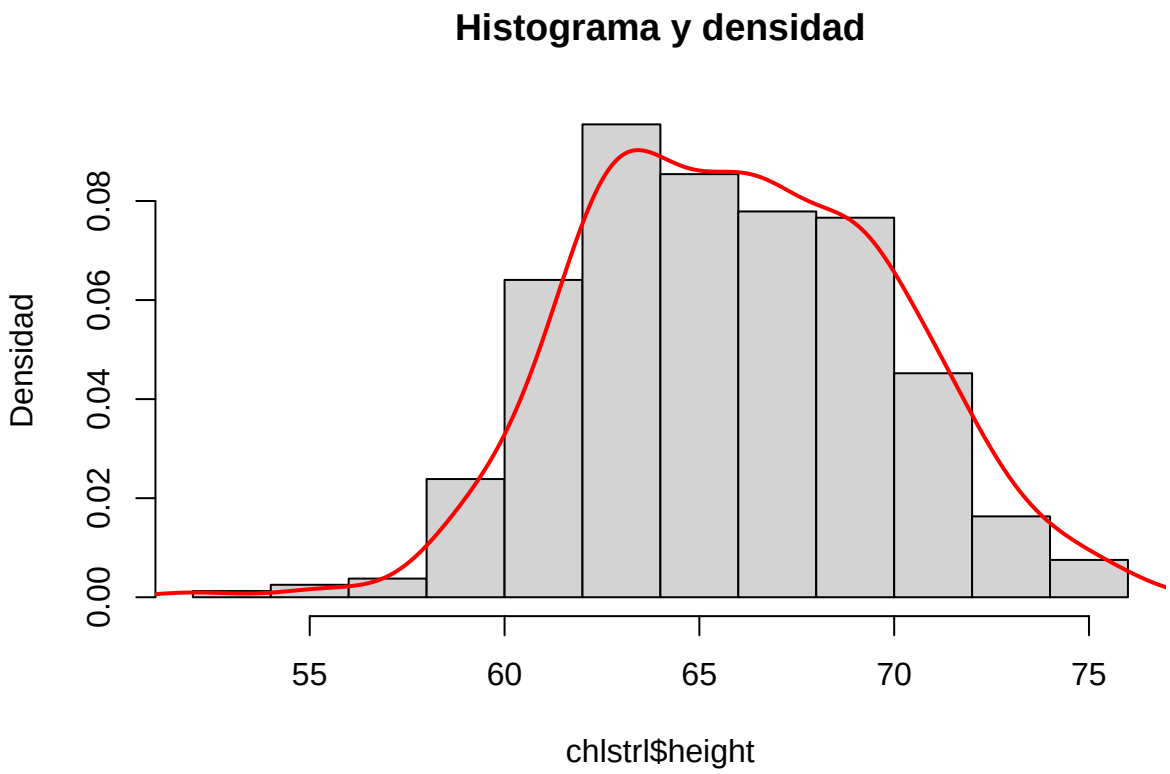


```
hist(chlstrl$weight,freq = FALSE, main = "Histograma y densidad",
     ylab = "Densidad")
dx <- density(chlstrl$weight,na.rm = TRUE)
lines(dx, lwd = 2, col = "red")
```

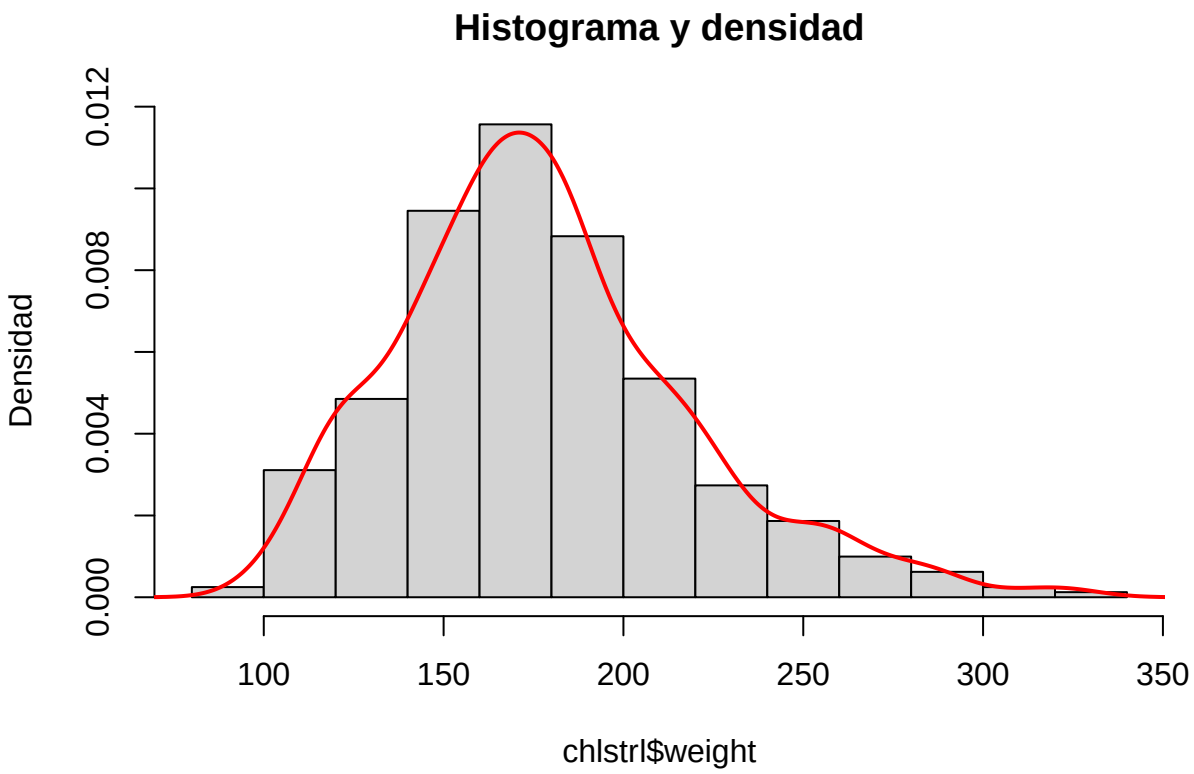


```
hist(chlstrl$waist,freq = FALSE, main = "Histograma y densidad",
     ylab = "Densidad")
dx <- density(chlstrl$waist,na.rm = TRUE)
lines(dx, lwd = 2, col = "red")
```

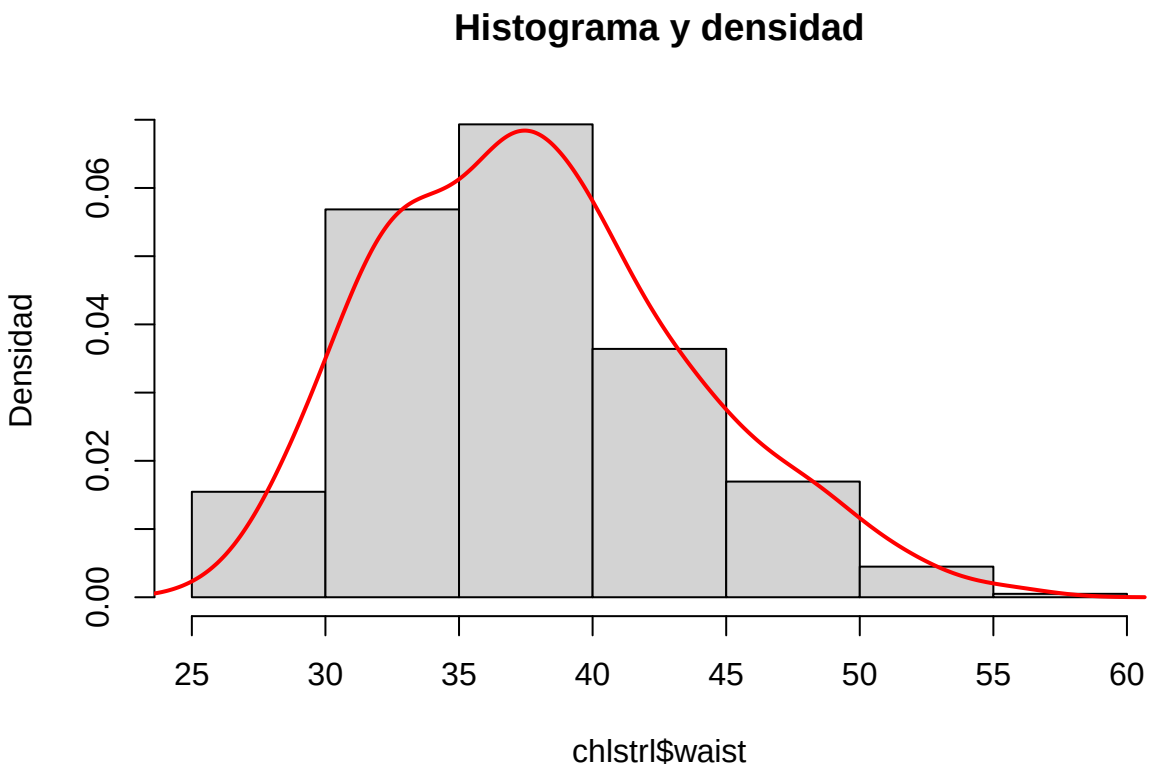


```
hist(chlstrl$hip,freq = FALSE, main = "Histograma y densidad",
     ylab = "Densidad")
dx <- density(chlstrl$hip,na.rm = TRUE)
lines(dx, lwd = 2, col = "red")
```

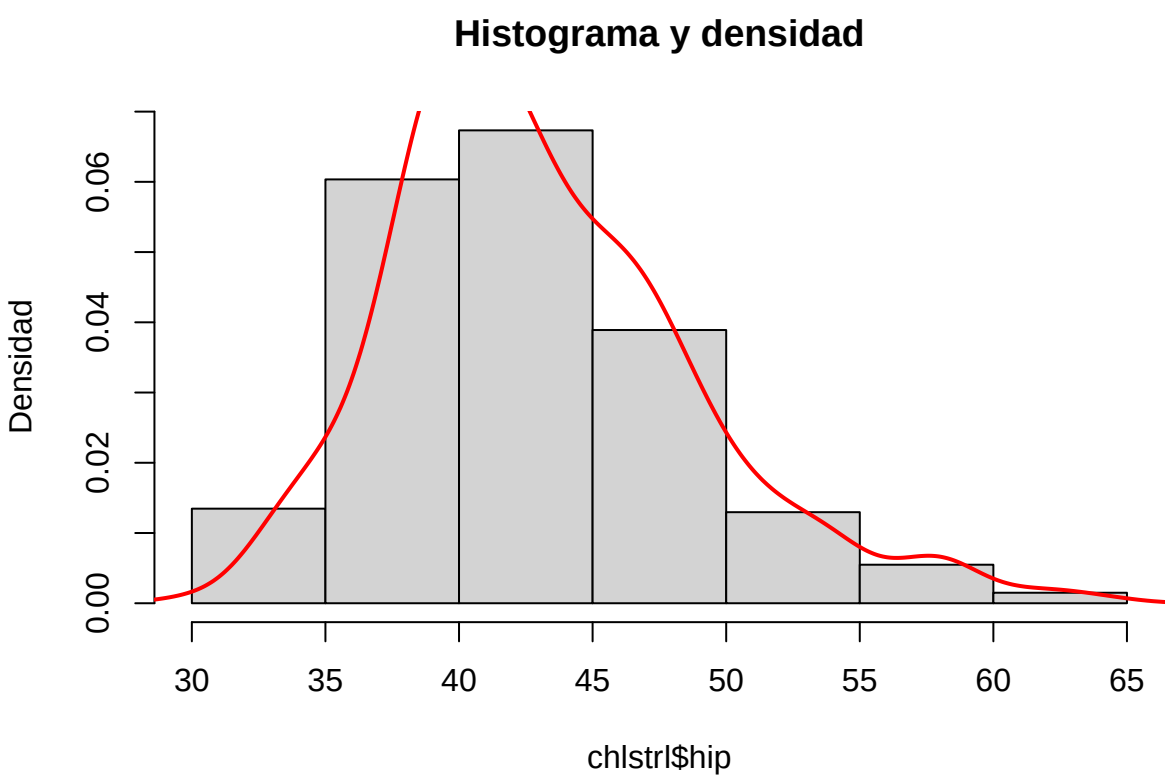


```
#Variables Categóricas


table(chlstrl$gender)
```

```
##
## female   male
##    234    169
```

```
prop.table(table(chlstrl$gender))
```

```
##
##    female      male
## 0.5806452 0.4193548
```

```
#medias de variables numéricas según género
chlstrl %>%
  group_by(gender) %>%
  summarise(meanChol = mean(chol, na.rm = TRUE),meanAge = mean(age, na.rm = TRUE), meanHeight = mean(he
```

```
## # A tibble: 2 x 7
##   gender meanChol meanAge meanHeight meanWeight meanWaist meanHip
##   <chr>     <dbl>   <dbl>      <dbl>      <dbl>     <dbl>   <dbl>
## 1 female     208.    45.8       63.7       174.      38.1    44.3
## 2 male       207.    48.3       69.1       182.      37.6    41.2
```

```
barplot(prop.table(table(chlstrl$gender)))
```

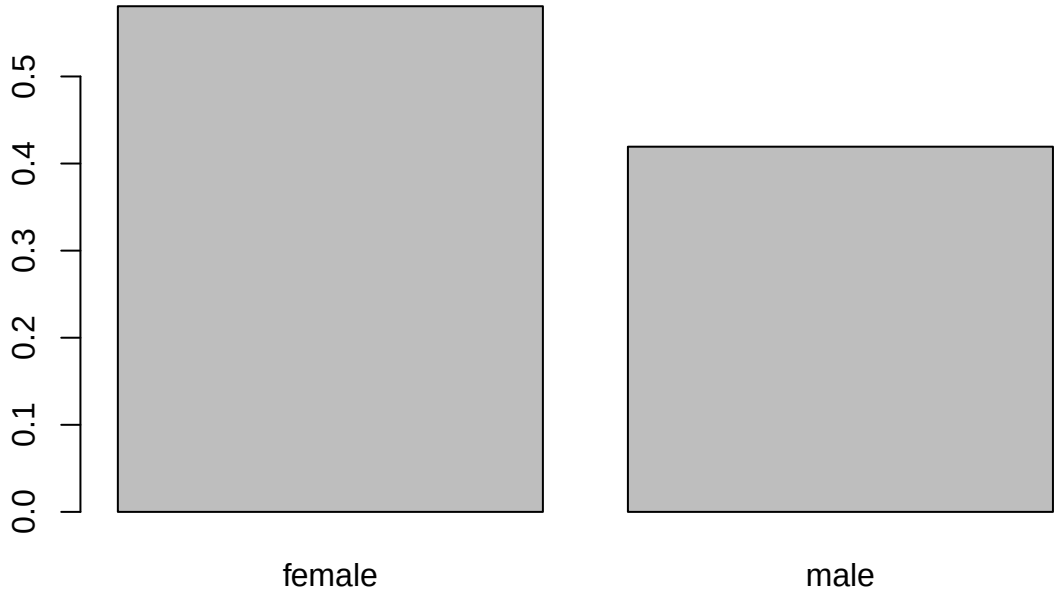

- Los valores de `height` y `weight` están en pulgadas (inches) y libras (pounds) respectivamente. Una libra son ≈ 0.454kg y una pulgada son ≈ 0.0254m. Usa dplyr para convertir esas columnas a metros y kilogramos respectivamente. Las nuevas columnas deben llamarse igual que las originales.

```
library(dplyr)
chlstrl0 = chlstrl %>%
  mutate(weight = weight * 0.454, height = height * 0.0254)
chlstrl0
```

```
## # A tibble: 403 x 7
##     chol   age gender height weight waist   hip
##    <dbl> <dbl> <chr>   <dbl>  <dbl> <dbl> <dbl>
##  1   203    46 female   1.57   54.9    29    38
##  2   165    29 female   1.63   99.0    46    48
##  3   228    58 female   1.55  116.     49    57
##  4    78    67 male     1.70   54.0    33    38
##  5   249    64 male     1.73   83.1    44    41
##  6   248    34 male     1.80   86.3    36    42
##  7   195    30 male     1.75   86.7    46    49
##  8   227    37 male     1.50   77.2    34    39
##  9   177    45 male     1.75   75.4    34    40
## 10   263    55 female   1.60   91.7    45    50
## # ... with 393 more rows
```

- Ahora usa esos valores de `height` y `weight` para añadir una nueva columna llamada BMI, definida mediante:

$$BMI = \frac{weight}{height^2}$$

(se divide por el cuadrado de la altura).

```
chlstrl0 = chlstrl0 %>%
  mutate(BMI = weight/(height^2))
chlstrl0
```

```
## # A tibble: 403 x 8
##     chol   age gender height weight waist   hip   BMI
##    <dbl> <dbl> <chr>   <dbl>  <dbl> <dbl> <dbl> <dbl>
##  1   203    46 female   1.57   54.9    29    38  22.2
##  2   165    29 female   1.63   99.0    46    48  37.5
##  3   228    58 female   1.55  116.     49    57  48.4
##  4    78    67 male     1.70   54.0    33    38  18.7
##  5   249    64 male     1.73   83.1    44    41  27.8
##  6   248    34 male     1.80   86.3    36    42  26.5
##  7   195    30 male     1.75   86.7    46    49  28.2
##  8   227    37 male     1.50   77.2    34    39  34.4
##  9   177    45 male     1.75   75.4    34    40  24.5
## 10   263    55 female   1.60   91.7    45    50  35.8
## # ... with 393 more rows
```

- Crea una nueva columna llamada `ageGroup` dividiendo la edad en los siguientes tres niveles:

  `(10,40], (40,70], (70,100]`

```
chlstrl0 = chlstrl0 %>%
  mutate(ageGroup = cut(age,breaks = c(10,40,70,100)))
chlstrl0
```

```
## # A tibble: 403 x 9
##     chol   age gender height weight waist   hip   BMI ageGroup
##    <dbl> <dbl> <chr>   <dbl>  <dbl> <dbl> <dbl> <dbl> <fct>
##  1   203    46 female   1.57   54.9    29    38  22.2 (40,70]
##  2   165    29 female   1.63   99.0    46    48  37.5 (10,40]
##  3   228    58 female   1.55  116.     49    57  48.4 (40,70]
##  4    78    67 male     1.70   54.0    33    38  18.7 (40,70]
##  5   249    64 male     1.73   83.1    44    41  27.8 (40,70]
##  6   248    34 male     1.80   86.3    36    42  26.5 (10,40]
##  7   195    30 male     1.75   86.7    46    49  28.2 (10,40]
##  8   227    37 male     1.50   77.2    34    39  34.4 (10,40]
##  9   177    45 male     1.75   75.4    34    40  24.5 (40,70]
## 10   263    55 female   1.60   91.7    45    50  35.8 (40,70]
## # ... with 393 more rows
```

- Usando `dplyr` calcula cuántas observaciones hay en cada nivel de `ageGroup` (indicación: usa `group_by`). Ahora, usando aquellas observaciones que corresponden a mujeres, ¿cuál es la media del nivel de colesterol y de BMI en cada uno de esos grupos de edad?

```
chlstrl0 %>%
  group_by(ageGroup) %>%
  summarise(n = n())
```

```
## # A tibble: 3 x 2
##   ageGroup     n
##   <fct>    <int>
## 1 (10,40]    160
## 2 (40,70]    207
## 3 (70,100]    36
```

```
chlstrl0 %>%
  filter(gender == "female") %>%
  group_by(ageGroup) %>%
  summarise(meanChol = mean(chol, na.rm = TRUE),
            meanBMI = mean(BMI, na.rm = TRUE))
```

```
## # A tibble: 3 x 3
##   ageGroup meanChol meanBMI
##   <fct>       <dbl>   <dbl>
## 1 (10,40]      189.    30.5
## 2 (40,70]      221.    30.3
## 3 (70,100]     230.    29.4
```

Ejercicio 2: Funciones de R.

- Crea una función de R llamada `cambiosSigno` que dado un vector `x` de números enteros no nulos, como

  `-12, -19, 9, -13, -14, -17, 8, -19, -14,`

  calcule cuántos cambios de signo ha habido. Es decir, cuántas veces el signo de un elemento es distinto del signo del elemento previo. Por ejemplo, en el vector anterior hay 4 cambios de signo (en las posiciones 3, 4, 7 y 8).

```
#ARREGLAR

y = c(-12,-19,9,-13,-14,-17,8,-19,-14)
u = c(1,-1,3)
cambiosSigno = function(x){
  difs = 0
  for(i in 1:(length(x)-1)){

    if(sign(x[i+1])!=sign(x[i])){
      difs = difs+1
    }
  }
  print(difs)
}
vec = sample(c(-100:1, 1:100), 20, replace = TRUE)
cambiosSigno(vec)
```

```
## [1] 4
```

- Modifica la función para que devuelva como resultado las posiciones donde hay cambios de signo. Llama `cambiosSignoPos(x)` a esa otra función. Por ejemplo, para el vector anterior el resultado de esta función sería [1] 3 4 7 8

```
#METER SAMPLE

cambiosSignoPos = function(x){
  posiciones = c()
  difs = 0
  for(i in 1:(length(x)-1)){

    if(sign(x[i+1])!=sign(x[i])){
      difs = difs+1
      posiciones = c(posiciones,i+1)
    }
  }
  print(difs)
  print(posiciones)
}
cambiosSignoPos(y)
```

```
## [1] 4
## [1] 3 4 7 8
```

También se valorará que incluyas en el código como usar ‘sample‘ para generar vectores aleatorios de 20

Ejercicio 3. R4DS.

Es recomendable que esta semana del curso hagas al menos una lectura somera de los Capítulos 1 a 5 de R for Data Science (R4DS), de H. Wickham, con énfasis especial en los Capítulos 3 y 5 (los capítulos 1, 2 y 4 son muy breves). Los siguientes apartados pretenden motivar esa lectura y por eso mismo pueden resultar un poco más laboriosos.

- Haz el ejercicio 6 de la Sección 3.6.1 de R4DS.

Gráfico 1:

```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy)) +
  geom_point() +
  geom_smooth(se = FALSE)
```

```
## ‘geom_smooth()‘ using method = ’loess’ and formula ’y ~ x’
```

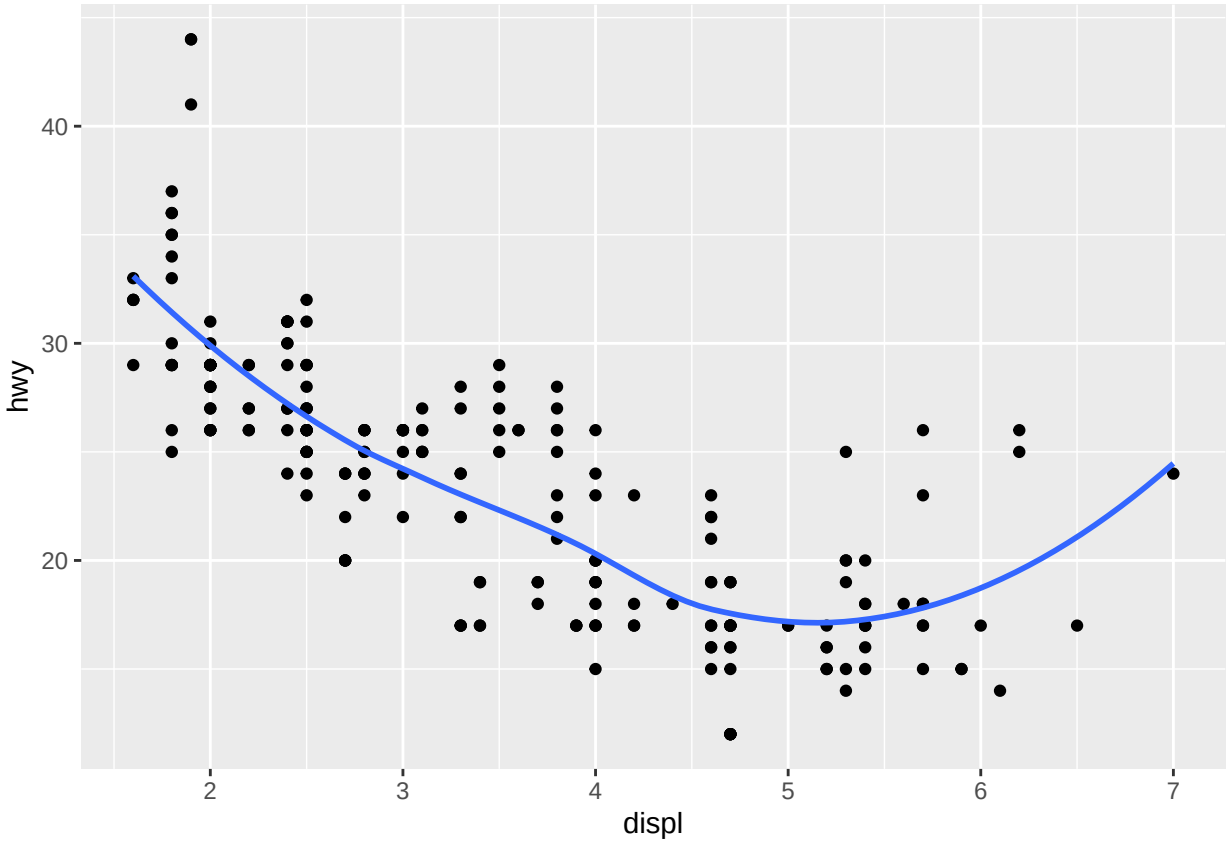

Gráfico 2:

```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy, group = drv)) +
  geom_point() +
  geom_smooth(se = FALSE)
```

```
## `geom_smooth()` using method = 'loess' and formula 'y ~ x'
```

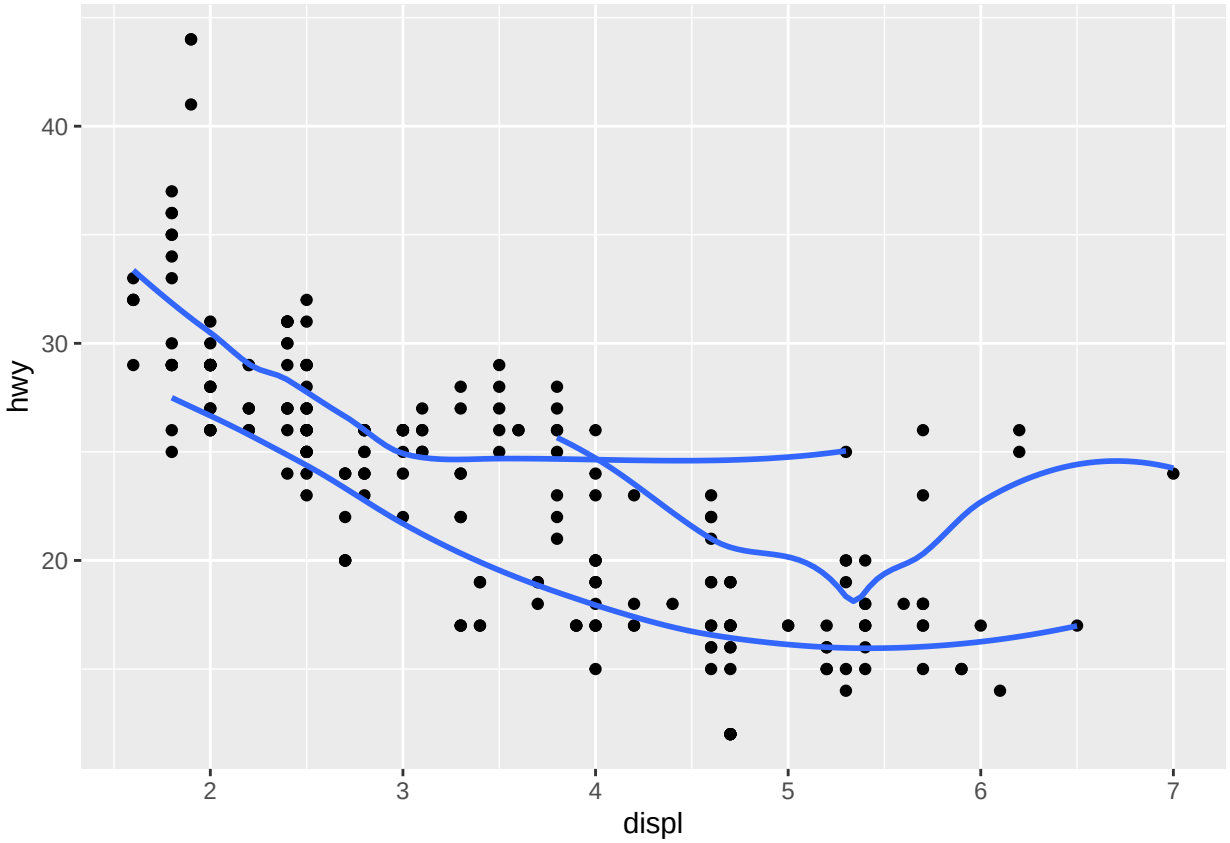

Gráfico 3:

```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy, colour = drv)) +
  geom_point() +
  geom_smooth(se = FALSE)
```

```
## `geom_smooth()` using method = 'loess' and formula 'y ~ x'
```

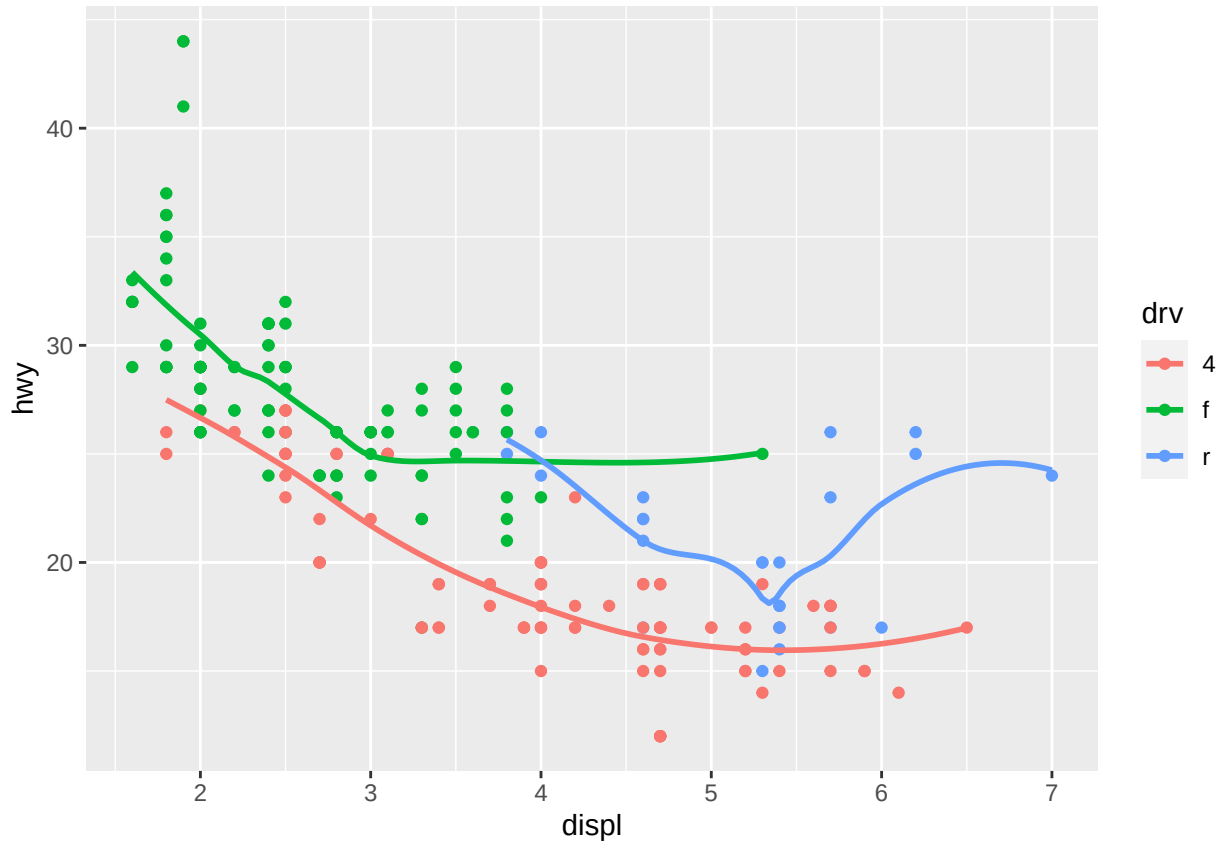

Gráfico 4:

```
ggplot() +
  geom_point(data = mpg, mapping = aes(x = displ, y = hwy, colour = drv)) +
  geom_smooth(data = mpg, mapping = aes(x = displ, y = hwy),se = FALSE)
```

```
## `geom_smooth()` using method = 'loess' and formula 'y ~ x'
```

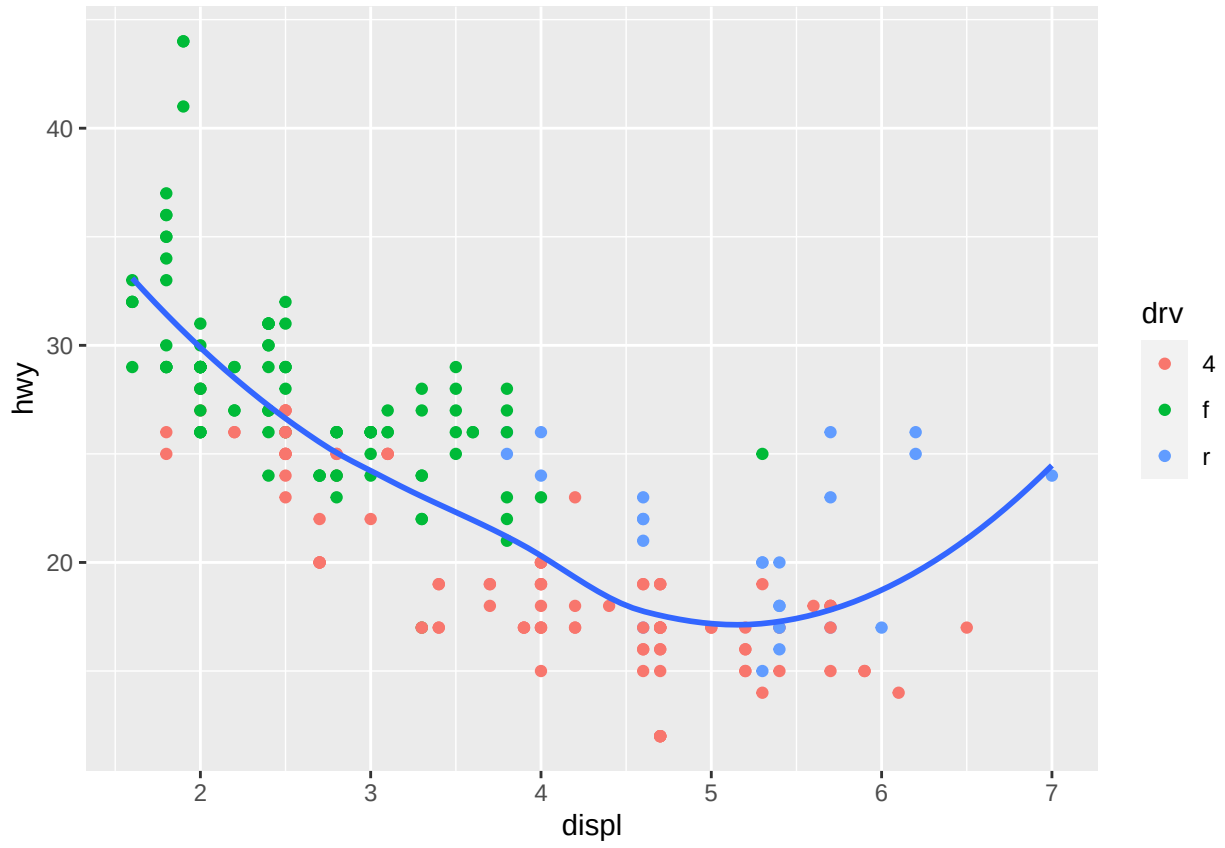

Gráfico 5:

```
ggplot() +
  geom_point(data = mpg, mapping = aes(x = displ, y = hwy, colour = drv)) +
  geom_smooth(data = mpg, mapping = aes(x = displ, y = hwy, linetype = drv),se = FALSE)
```

```
## `geom_smooth()` using method = 'loess' and formula 'y ~ x'
```

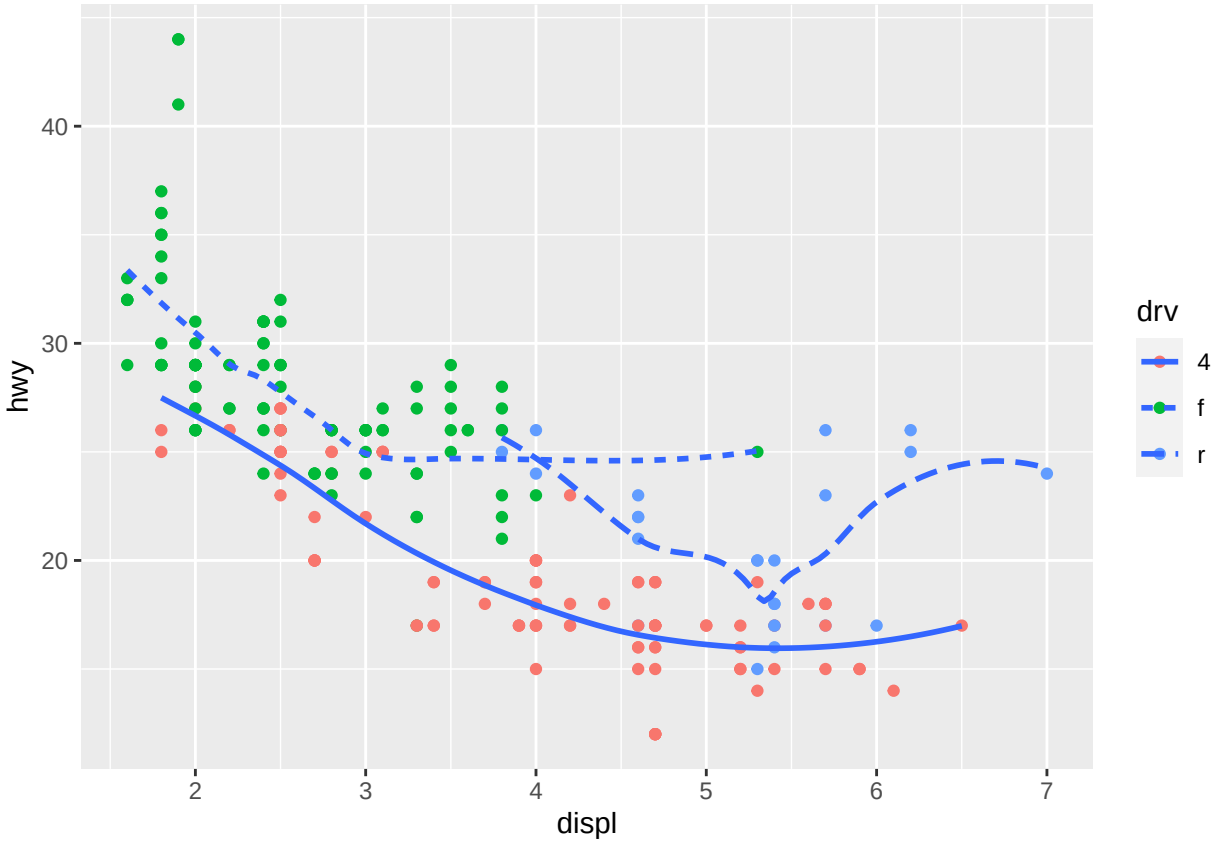

Gráfico 6:

```
ggplot(mpg, aes(x = displ, y = hwy)) +
  geom_point(size = 4, color = "white") +
  geom_point(aes(colour = drv))
```

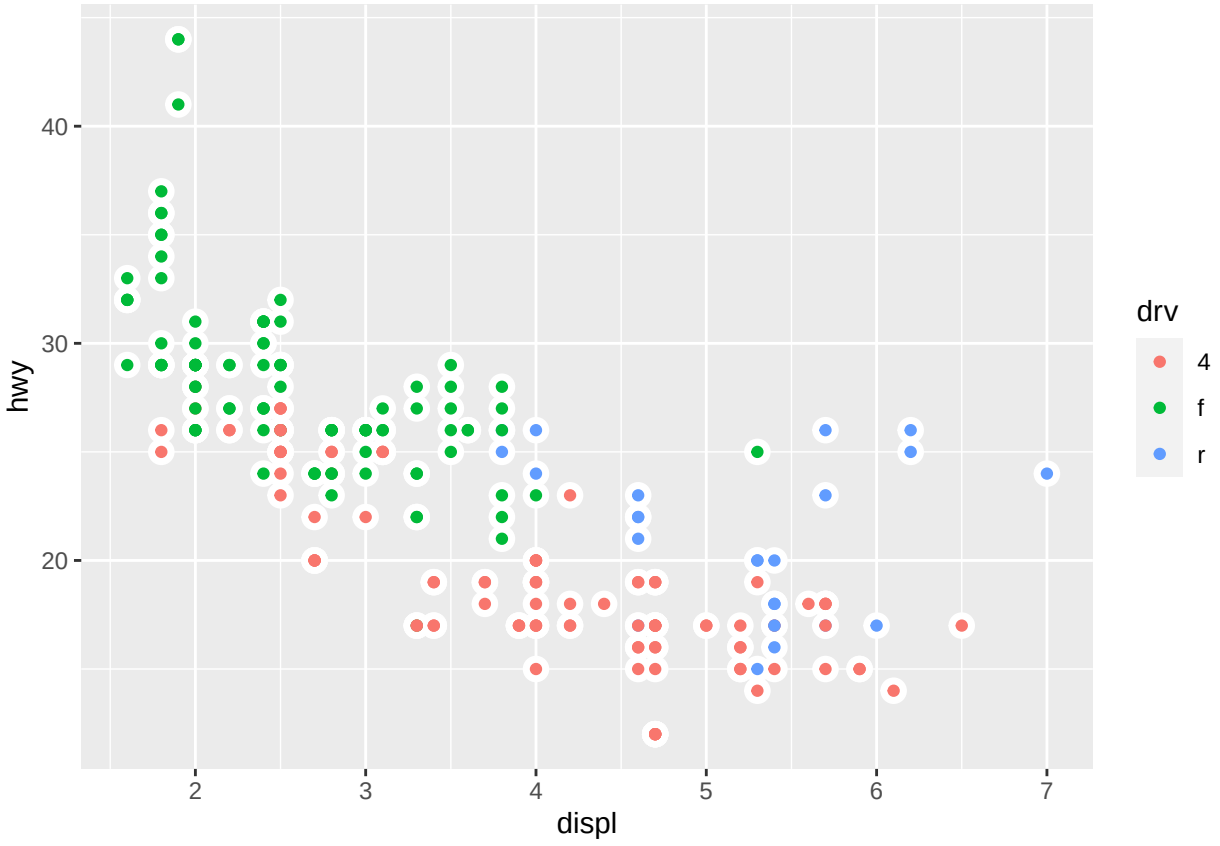

- Haz el ejercicio 1 de la Sección 5.2.4 de R4DS.

```
library(nycflights13)
```

```
## Warning: package 'nycflights13' was built under R version 4.1.1
```

```
flights
```

```
## # A tibble: 336,776 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      517            515         2      830            819
##  2  2013     1     1      533            529         4      850            830
##  3  2013     1     1      542            540         2      923            850
##  4  2013     1     1      544            545        -1     1004           1022
##  5  2013     1     1      554            600        -6      812            837
##  6  2013     1     1      554            558        -4      740            728
##  7  2013     1     1      555            600        -5      913            854
##  8  2013     1     1      557            600        -3      709            723
##  9  2013     1     1      557            600        -3      838            846
## 10  2013     1     1      558            600        -2      753            745
## # ... with 336,766 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
flights %>%
  filter(arr_delay >= 120)
```

```
## # A tibble: 10,200 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      811            630       101     1047            830
##  2  2013     1     1      848           1835       853     1001           1950
##  3  2013     1     1      957            733       144     1056            853
##  4  2013     1     1     1114            900       134     1447           1222
##  5  2013     1     1     1505           1310       115     1638           1431
##  6  2013     1     1     1525           1340       105     1831           1626
##  7  2013     1     1     1549           1445        64     1912           1656
##  8  2013     1     1     1558           1359       119     1718           1515
##  9  2013     1     1     1732           1630        62     2028           1825
## 10  2013     1     1     1803           1620       103     2008           1750
## # ... with 10,190 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
flights %>%
  filter(dest == "IAH"|dest == "HOU")
```

```
## # A tibble: 9,313 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      517            515         2      830            819
##  2  2013     1     1      533            529         4      850            830
##  3  2013     1     1      623            627        -4      933            932
##  4  2013     1     1      728            732        -4     1041           1038
##  5  2013     1     1      739            739         0     1104           1038
##  6  2013     1     1      908            908         0     1228           1219
##  7  2013     1     1     1028           1026         2     1350           1339
##  8  2013     1     1     1044           1045        -1     1352           1351
##  9  2013     1     1     1114            900       134     1447           1222
## 10  2013     1     1     1205           1200         5     1503           1505
## # ... with 9,303 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
flights %>%
  filter(carrier == "DL"|carrier == "UA"|carrier == "")
```

```
## # A tibble: 106,775 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      517            515         2      830            819
##  2  2013     1     1      533            529         4      850            830
##  3  2013     1     1      554            600        -6      812            837
##  4  2013     1     1      554            558        -4      740            728
##  5  2013     1     1      558            600        -2      924            917
##  6  2013     1     1      558            600        -2      923            937
```

```
##  7  2013     1     1      559            600        -1      854            902
##  8  2013     1     1      602            610        -8      812            820
##  9  2013     1     1      606            610        -4      837            845
## 10  2013     1     1      607            607         0      858            915
## # ... with 106,765 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
flights %>%
  filter(month == 7|month == 8| month == 9)
```

```
## # A tibble: 86,326 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     7     1        1           2029       212      236           2359
##  2  2013     7     1        2           2359         3      344            344
##  3  2013     7     1       29           2245       104      151              1
##  4  2013     7     1       43           2130       193      322             14
##  5  2013     7     1       44           2150       174      300            100
##  6  2013     7     1       46           2051       235      304           2358
##  7  2013     7     1       48           2001       287      308           2305
##  8  2013     7     1       58           2155       183      335             43
##  9  2013     7     1      100           2146       194      327             30
## 10  2013     7     1      100           2245       135      337            135
## # ... with 86,316 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
flights %>%
  filter(arr_delay >= 120 & dep_delay == 0)
```

```
## # A tibble: 3 x 19
##    year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##   <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
## 1  2013    10     7     1350           1350         0     1736           1526
## 2  2013     5    23     1810           1810         0     2208           2000
## 3  2013     7     1      905            905         0     1443           1223
## # ... with 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
#MAL
flights %>%
  filter(dep_delay >= 60 & arr_delay <= 30)
```

```
## # A tibble: 239 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     3     1850           1745        65     2148           2120
##  2  2013     1     3     1950           1845        65     2228           2227
##  3  2013     1     3     2015           1915        60     2135           2111
##  4  2013     1     6     1019            900        79     1558           1530
```

```
##  5  2013     1     7     1543           1430        73     1758           1735
##  6  2013     1    11     1020            920        60     1311           1245
##  7  2013     1    12     1706           1600        66     1949           1927
##  8  2013     1    12     1953           1845        68     2154           2137
##  9  2013     1    19     1456           1355        61     1636           1615
## 10  2013     1    21     1531           1430        61     1843           1815
## # ... with 229 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
flights %>%
  filter(dep_time >= 0000 & dep_time <=0600)
```

```
## # A tibble: 9,344 x 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      517            515         2      830            819
##  2  2013     1     1      533            529         4      850            830
##  3  2013     1     1      542            540         2      923            850
##  4  2013     1     1      544            545        -1     1004           1022
##  5  2013     1     1      554            600        -6      812            837
##  6  2013     1     1      554            558        -4      740            728
##  7  2013     1     1      555            600        -5      913            854
##  8  2013     1     1      557            600        -3      709            723
##  9  2013     1     1      557            600        -3      838            846
## 10  2013     1     1      558            600        -2      753            745
## # ... with 9,334 more rows, and 11 more variables: arr_delay <dbl>,
## #   carrier <chr>, flight <int>, tailnum <chr>, origin <chr>, dest <chr>,
## #   air_time <dbl>, distance <dbl>, hour <dbl>, minute <dbl>, time_hour <dttm>
```